

탐구계획서

주제 : 눈은 왜 두 개인가?

1. 탐구 동기

최근 'Attention Is All You Need' 등 트랜스포머(Transformer) 기반의 컴퓨터 비전(CV) 논문을 탐구하던 중, STTR(Stereo Transformer)과 같은 스테레오 뎁스 추정 알고리즘에 관심을 갖게 되었다.

동시에 테슬라(Tesla) FSD 등이 라이다(LiDAR)를 배제하고 카메라 센서만으로 공간을 인식하려는 시도와 센서 수를 줄이는 'Vision Only' 트렌드를 접하며 근본적인 의문이 생겼다.

"왜 인간은 진화 과정에서 눈을 2개만 갖게 되었을까? 3개, 4개일 때 심도(Depth) 인식의 정확도가 더 높다면, 생존에 더 유리하지 않았을까?"

기존의 진화론적 설명은 직관적이나 수학적/공학적 정량 데이터가 부족하다는 점에 착안하여, 딥러닝 모델을 이용해 카메라 개수($N=2, 3, 4...$)에 따른 '정확도(Accuracy) 대비 연산 효율성(Computational Cost)'을 시뮬레이션해보고자 한다. 이를 통해 인간 눈이 2개인 공학적 이유를 증명하고, 나아가 로봇 공학에서 상황별 최적의 센서 구성을 제안하는 '로보틱 센서 포뮬러'를 도출해보고자 한다.

2. 탐구 과제

가. 인간 시각 시스템의 하이퍼 파라미터 정의 및 모델링

1. 입력 프레임(FPS): 인간의 임계 융합 주파수(CFF)와 신경 전달 속도를 고려하여 60~100Hz 가변 입력과 30Hz 추론 속도로 설정.
2. 화질(Resolution): 5.76억 화소의 망막 정보가 시신경(약 120만 개)을 통해(roger N.clark 박사의 "576 메가픽셀(5억 7,600만 화소)" 이론으로 계산함) 압축 전달되는 과정을 모사하여, FHD~4K 수준의 유효 해상도로 리사이징(Resizing)하는 전처리 기준 수립.
3. 시야각(FOV) 및 기저선(Baseline): 인간의 평균 시야각(120°)과 동공 간 거리(IPD)를 반영한 시뮬레이션 환경 구축.

나. Transformer 기반 N-View 뎁스 추정 모델 설계

1. STTR 및 MVS 알고리즘 분석: 기존 CNN 기반의 에피폴라 라인(Epipolar Line) 제약에서 벗어나, 글로벌 컨텍스트(Global Context)를 이해하는 트랜스포머 기반 모델(STTR 변형) 설계.
2. STTR 논문에 제시된 DP기반 기존 알고리즘을 도입함으로써 각 카메라 개수 별 위치 최적화 시도 (attention 기반의 매커니즘은 디스퍼티에 영향이 적기 때문에 학습시간에 비해 비효율성이 들어난다 이것을 보완하기 위해 기존의 DP기반 알고리즘을 통해 빠르게 위치 최적화를 시도한다)
3. 가변적 카메라 셋업($N=2, 3, 4$): 카메라 개수가 늘어날 때, 사각지대(Occlusion) 감소율과 심도 추정 정확도(Disparity Error)의 변화 추이 측정.
4. 연산량 측정: 카메라 증가에 따른 FLOPs(초당 부동소수점 연산) 및 인퍼런스 레이턴시(Inference Latency) 증가폭 측정.

다. '정확도-효율성' 상관관계 분석 및 최적화 수식 도출

1. 비용 함수(Cost Function) 정의: 정확도 이득과 연산 비용을 변수로 하는 최적화 수식(L) 설계.
2. 임계점(Threshold) 탐색: $N=2$ 에서 $N=3, 4$ 로 넘어갈 때, 정확도 상승폭이 연산 비용 증가폭보다 낮아지는 '수확 체감의 법칙(Diminishing Returns)' 구간 탐색.
3. Foveated Rendering 가설 검증: 인간처럼 중심부만 고해상도로 처리할 경우 N 값 변화에 따른 효율성 변화 비교 분석.
4. 탐구 방법

[선행 연구 및 환경 구축]

1. 관련 논문(STTR, MVSNet 등) 분석 및 GitHub 오픈소스 코드 리팩토링.
2. Python(PyTorch) 환경에서 가상 3D 환경(Blender 또는 Unity)을 이용해 동일한 씬(Scene)을 카메라 2, 3, 4개로 촬영한 데이터셋 생성.

[실험 진행]

1. **Case 1** ($N = 2$): 인간과 동일한 양안 구조. Baseline 거리 변화에 따른 오차율 측정.
2. **Case 2** ($N = 3$): Tri-focal Tensor 기하학 구조. 가려진 영역(Occlusion) 복원 능력과 연산량 증가분 비교.
3. **Case 3** ($N = 4$ 이상): 과잉 센서 환경. 정확도 상승의 포화 시점(Saturation Point) 확인.

[결과 분석]

1. 획득한 Depth Map과 Ground Truth(실제 깊이값) 간의 에러율(EPE) 비교.
2. 도출된 데이터를 바탕으로 로봇의 목적(정밀 작업 vs 고속 주행)에 따른 최적 센서 개수 가이드라인 작성.
3. 예상되는 결과

진화론적 타당성 검증: 실험 결과를 통해 인간의 뇌 용량(에너지 소비) 대비 시각 정보의 정확도를 최대화하는 최적점이 $N = 2$ (양안)임을 수학적으로 증명한다. (3개 이상일 때 연산 비용 급증 대비 정확도 상승 미미)

로보틱스 센서 포물러(L_{total}) 제시:

$$L_{total} = \alpha \cdot (1 - Accuracy) + \beta \cdot (ComputationalCost)$$

위 수식을 통해 배터리 효율이 중요한 모바일 로봇은 $N = 2$, 정밀도가 생명인 수술 로봇은 $N \geq 3$ 등 목적에 따른 명확한 하드웨어 설계 가이드라인을 제시한다.

딤러닝 모델 최적화: 트랜스포머 어텐션 메커니즘을 활용하여 카메라 간의 기하학적 구속조건 없이도 유연하게 뎁스를 추론하는 경량화 모델 프로토타입 확보.