

github :

## Abstract

LLM의 수학적 추론은 상당히 많이 발전했다. 이러한 수학적 추론은 AI의 중요한 시험대이며 더 발전한다면 과학 연구에도 영향을 줄 수 있다. 강화 학습을 통해 LLM의 수학적 추론 능력이 향상되면서, 수학 경시 대회는 변별력의 한계에 이르렀다. 하지만 최종 ntroduction답으로 보상을 주는 방식에는 두 가지 한계가 있다.

- 정답을 맞혀도 추론 과정은 틀릴 수 있다
- 정리 증명에는 애초에 최종 답이 없어 적용조차 안 된다

그래서 이 논문은 self-verification 가능한 수학적 추론을 위해 LLM 기반 검증기 훈련 방법에 대해 연구했다.

- 검증기를 보상 모델로 삼아 증명 생성기를 훈련하고 생성기가 증명을 확정하기 전 문제점을 발견하고 해결하도록 유도하기
- 생성기가 강화됨에 따라 생성기와 검증기의 격차를 유지하기 위해서 검증하기 어려운 새로운 증명에 자동으로 라벨을 붙이고 검증기를 더욱 개선할 훈련 데이터를 만들기

DeepSeekMath-V2는 강력한 정리 증명 능력을 보이며 Putnam 2024에서 118/120으로 인간 최고점 90점을 넘어섰다

## Introduction

수학적 추론을 위한 LLM RL 학습에서 검증기가 생성기보다 앞서 있어야 학습이 유효한데 생성기가 강해지면 이 격차가 사라진다. 이러한 생성-검증 격차의 부재는 추가적인 개선을 막는다.

해당 논문에서는 이를 해결하기 위해 LLM 검증 능력 개발을 제안한다. 논문에서는 3가지 관찰을 통해 접근한다.

- 인간은 참조 해답 없이도 증명에서 문제점을 찾을 수 있다.(검증은 국소적이기 때문)
- 검증 노력을 확장했음에도 아무런 문제점이 발견되지 않는다면 그 증명은 유효할 가능성이 높다
- 찾기 어려울 수록 좋은 증명이며 이는 증명 생성을 최적화하는데 활용 가능하다.

이러한 요소를 통해 검증기는 다음과 같은 반복적 개선 순환을 가능하게 한다.

- 검증 피드백을 이용해 증명 생성을 최적화
- 검증 연산을 확장해 검증하기 어려운 새 증명에 자동으로 라벨을 붙여 검증기 자체를 개선
- 향상된 검증기로 증명 생성을 더욱 최적화

믿을 만한 검증기가 있다면 생성기에게도 검증기처럼 자신의 증명을 평가하도록 가르칠 수 있다. 이를 통해 생성기는 문제점을 찾아내거나 해결할 수 없을 때까지 자신의 증명을 반복적으로 정제할 수 있다.

본질적으로 생상 모델의 자체 채점을 통해 모델이 자신이 보상을 더 많이 받는 방법을 인식하고 단순 시행착오가 아니라 의도적인 추론을 통해 그 보상을 최대화할 수 있게 한다.

## Method

### 전체 파이프 라인 요약

수학 문제를 수집하고 기존 LLM이 문제에 대한 증명을 한다. 사람이 생성된 증명을 보고 0/0.5/1로 채점한다. 문제, 문제에 대한 증명, 그 증명에 대한 점수를 데이터셋으로 검증기를 학습한다. 이를 통해 검증기는 증명을 보고 점수를 매길 수 있게 된다. 여기서 검증기가 점수를 매기고 틀린 이유를 설명하게 되는데 이 틀린 부분 지적이 타당한지 사람이 판단하고 새로 만든 (문제, 증명, 검증, 검증의 타당성) 으로 새 데이터를 만들어 메타 검증기를 학습한다. 이제 메타 검증기의 평가를 보상으로 검증기를 GRPO로 강화학습한다. 그 후 생성기를 강화학습 하는데 생성기는 문제에 대한 증명과 그 증명에 대한 평가(증명이 완벽함 혹은 특정 부분이 빈약할 수 있음)를 출력한다. 검증기는 생성된 증명을 채점하고 생성기의 자기 평가가 자신의 채점 결과와 얼마나 일치하는지를 평가한다. 증명의 품질 점수와 자기 평가의 일치도를 합친 보상을 이용해 GRPO로 강화학습한다. 이제 강화학습으로 인해 생성기가 강해졌다면 검증기도 이에 맞게 강화되어야한다.

생성기의 증명에 대해 검증기를 여러 번 돌린 뒤 검증기의 평가를 다시 한번 메타 검증기로 평가한다.  
이 메타 검증기의 평가 까지 통과되었다면 그 증명과 평가는 신뢰가 높다고 할 수 있다.  
이 신뢰 높은 데이터를 새로운 라벨 데이터로 만들어 검증기를 학습시킵니다.