

수학적 이해

머신러닝의 가장 기본적인 목표는 데이터의 **입력** x 가 있고 그에 따른 **출력** y 를 만들어 내는 함수를 만드는 것이다.

이 함수를 만드는데 필요한 요소들은 아래 4가지이다.

1. 데이터
2. 가설
3. 손실
4. 경사하강법

우선 예시를 통해 선형 회귀가 쓰이는 사례를 알아보자면

어떤 학생이 1시간 공부를 했더니 2점
다른 학생이 2시간 공부를 했더니 4점
또 다른 학생이 3시간을 공부했더니 6점을 맞았습니다.
그렇다면, "내가 4시간을 공부한다면 몇 점을 맞을 수 있을까요?"

이런식으로 입력값과 출력값이 비례관계에 있을 때 사용해 볼 수있다.

이것을 데이터로 표현한다면?

아래와 같이 표현할 수 있다.

데이터

$$x = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \quad y = \begin{pmatrix} 2 \\ 4 \\ 6 \end{pmatrix}$$

여기서 x 는 공부한 시간, y 는 x 값에 매핑(mapping) 되는 점수를 의미한다.

- **mapping** : 어떤 값이나 요소를 다른 값이나 요소에 짝지어 연결하는 과정

가설

가설(hypothesis) 함수는 우리가 만들 함수를 의미하며 기본적으로 머신러닝에서 학습될 함수는 데이터의 형태나 구조를 보고 결정한다.

위에 제시된 데이터의 경우 선형성 즉, 일차 함수꼴을 하고 있기에 아래 가설를 설정한다.

$$H(x) = wx + b$$


여기서 w , b 를 각각 weight(가중치)와 bias(편향)이라고 한다.

손실

손실 함수는 비용 함수, 오차 함수, 목적 함수 등 다양한 이름을 가진다.

여기서 손실 함수의 기본적인 모델링은 기존 우리가 예측해야 할 함수에서 벗어난다면 값을 크게 예측해야 할 함수에 가깝다면 낮은 값이 나오도록 하는 것이다.

예를 들어



위의 그림처럼 선형 회귀는 기본적으로 입력값 x 에 대해 올바른 출력값 y 를 찾아야한다.
그렇기에 같은 x 에 대해 출력값과 예측값 $\hat{y}$ 의 차이를 손실 함수에 반영하면 된다.
(손실 함수의 최솟값이 곧 가설 함수의 최적의 형태)

선형 회귀 분석에서 가장 많이 쓰이는 함수가 바로 평균 제곱 오차(MSE)이다.
이는 분산과 같은 식이지만 분산은 데이터의 흩어진 정도를 비교하고 MSE는 모델의 예측이 얼마나 틀렸는가를 나타낸다는 데에 의미적 차이가 존재한다.

식

$$cost(W, b) = \frac{1}{n} \sum_{i=1}^n \left[y^{(i)} - H(x^{(i)}) \right]^2$$

경사하강법(Gradient descent)


경사하강법이란 옵티마이저(optimizer) 알고리즘의 한 종류로
최적화 알고리즘이라고도 한다.

위에서 설명했듯이 입력값에 대해 적절한 출력값을 만드는 "함수"를 만드는 방법은 예측이 정답에 가까울 수록 값이 작아지고 예측이 정답에서 멀어질 수록 값이 커지는 함수의 최솟값을 찾으면 된다.


우리가 각 변수 w 와 b 의 변화에 따른 손실 함수 $cost(W, b)$ 의 변화량은 알 수 없지만 $cost(W, b)$ 를 각 변수로 미분하면 해당 w, b 값에서의 기울기를 알 수 있다.

손실 함수를 설계함에 있어 w 와 b 의 변화에 따른 손실 함수는 이차 함수의 형태를 띤다는 것을 대략적으로 알 수 있다.

이해를 쉽게 하기 위해 가중치 w 에 대해서만 생각해보자
우선 가중치 w 를 x 축으로 $cost(W, b)$ 를 y 축으로 하는 함수는 아래의 형태를 보일 것이다.



여기서 $cost(w, b)$ 를 w 로 미분하면 그 지점에서의 기울기가 나온다.



그런데 여기서 잘 관찰해본다면 접선의 기울기가 양수 일 때는 w 를 음수(왼쪽) 방향으로 음수 일 때는 w 를 양수 방향으로 이동해야 한다는 것을 알 수 있다.

$$gradient = \frac{\partial cost(W)}{\partial W}$$


기울기는 위와 같이 정의 가능하다.

새로운 W 를 업데이트 하는 수식은 아래와 같다. ($:=$ 는 대입한다는 뜻)

$$W := W - \alpha \times gradient$$

$$W := W - \alpha \frac{\partial cost(W)}{\partial W}$$

기본적으로 기울기가 양수(+)이면 음수(-)방향,
기울기가 음수(-)이면 양수(+)방향으로 이동해야 하므로 $gradient$ 에 $-$ 를 붙혀 사용한다.
 α 를 사용하는 이유는 w 값의 변화에 따라 기울기는 엄청나게 클수도 작을수도 있다. 그렇기에
아주 작은 값 α (일명 learning rate)를 붙혀준다.
이는 단순히 값 변화의 안정성 뿐만 아니라 변화량에 의해 업데이트 값이 발산하는 것을 막아준다.



최종 수식 유도

마지막으로 $gradient$ 수식을 유도해보며 마무리하겠다.
우선 값의 업데이트는 전 단계를 기준으로 w 와 b 값이 각각 일어나며 이 값을 한 번 업데이트 하는 과정을
스텝(step)이라고 한다.

실제 계산 과정을 살펴보자

Weight

우선 바깥 함수와 안 함수를 각각 미분해서 곱하는 체인 룰을 사용한다.

바깥 함수

$$\frac{2}{n} \sum_{i=1}^n \left(y^{(i)} - (Wx^{(i)} + b) \right)$$

안쪽 함수

$$\frac{\partial}{\partial W} \left(y^{(i)} - Wx^{(i)} - b \right) = -x^{(i)}$$

최종

$$\frac{\partial cost}{\partial W} = \frac{1}{n} \sum_{i=1}^n 2 \left(y^{(i)} - (Wx^{(i)} + b) \right) \cdot (-x^{(i)})$$

$$\frac{\partial cost}{\partial W} = -\frac{2}{n} \sum_{i=1}^n x^{(i)} \left(y^{(i)} - H(x^{(i)}) \right)$$

Bias

$$cost(W, b) = \frac{1}{n} \sum_{i=1}^n \left(y^{(i)} - (Wx^{(i)} + b) \right)^2$$

바깥 함수

$$\frac{1}{n} \sum_{i=1}^n 2 \left(y^{(i)} - (Wx^{(i)} + b) \right)$$

안쪽 함수

$$\frac{\partial}{\partial b} \left(y^{(i)} - Wx^{(i)} - b \right) = -1$$

최종

$$\frac{\partial cost}{\partial b} = \frac{1}{n} \sum_{i=1}^n 2 \left(y^{(i)} - (Wx^{(i)} + b) \right) \cdot (-1)$$

$$\frac{\partial cost}{\partial b} = -\frac{2}{n} \sum_{i=1}^n \left(y^{(i)} - H(x^{(i)}) \right)$$