



관련 논문

논문	링크
DeepSeekMath (GRPO)	
DeepSeek-Prover-V2	
Kimina-Prover	
BFS-Prover	
Seed-Prover	
DeepSeekMath-V2	
ppo	

그 외 자료

자료	링크
2026_problems	
Loop	


최근들어 LLM들을 통해 수학 분야의 미해결 난제를 풀어내는 일들이 많이 다루어지고 있습니다.

- GPT 6 를 통한 10개의 난제 해결
- Fable 5 를 활용한 야코비안 추측 반례

이를 통해 LLM을 통한 난제 증명에 대한 궁금증이 생겼고 이번 논문 리뷰와 해석을 담은 문서를 통해 해당 궁금증을 해소할 것입니다.

배경지식


1. Lean



수학 증명을 코드로 작성하고 컴파일러를 통해 해당 증명인지 참인지 판단하는 언어이다.

명제 p 를 타입으로 정의하고 타입 p 를 가진 값 하나 만들었다 가 곧 p 를 증명했다와 동치임을 이용한다.
모든 증명을 커널이 판단 가능한 원시 항으로 쪼개서 검수한다.

2. mathlib



Lean 4용 수학 통합 라이브러리 (수학 정리를 모아둔 단일 레포)

규모가 정리 20만개 이상으로 거대하다.
범위는 집합론, 대수, 해석학, 위상수학, 범주론, 정수론, 확률론 등이 있다.
증명을 굉장히 편하게 도와준다.



Fermat's Last Theorem(페르마의 마지막 정리) 증명을 Lean 으로 옮기는 프로젝트인데 증명 과정에서 mathlib에 많은 기여를 하고 있다.

3. PPO

원리

ppo는 proximal policy optimization의 약자로 이름 그대로 정책을 최적화하는 알고리즘이다.
기존 정책 업데이트 알고리즘들을 단계가 지날 때 정책 변화가 급격히 일어나는 것을 보완한 알고리즘이다.

강화학습이란 흔히 어떤 행동에 대한 보상 정도로 여겨지는데
사실 많이 사용되는 지도학습들의 알고리즘과 유사하다.

강화학습의 forward 과정 또한 신경망의 형태를 하고 있다.
가장 단순한 형태로 출력층이 softmax인 신경망 있다.

신경망은 현재의 상태를 입력으로 받아 행동을 출력한다. (softmax를 통해 확률로 출력)

왼쪽 : 0.15
오른쪽 : 0.30
점프 : 0.55

이런 식으로 확률을 출력하고 이에 대한 보상을 받는다.

수식 해석

$$Loss^{clip} = E^t[\min(rt(\theta)A^t, clip(rt(\theta), 1 - \epsilon, 1 + \epsilon)A^t)]$$

$$\pi(a \mid s)$$

상태 s 가 주어졌을 때 행동 a를 선택할 확률

상태 s는 벡터로 주어지며 이를 통해 정책이 입력이 아닌 softmax를 통한 확률 출력임을 알 수 있다.

왼쪽 : $\pi(\text{왼쪽} \mid s)$
오른쪽 : $\pi(\text{오른쪽} \mid s)$
점프 : $\pi(\text{점프} \mid s)$

$$A(a, s)$$

상태 s 에서 a 행동을 할 때 실제 얻은 가치 - 예상 가치

PPO에서는 신경망을 두 개 사용한다.
위에서 설명한 행동에 대한 확률을 예측하는 Policy network 와 행동에 대한 가치를 예측하는 Value Network 이다.

$$r(\theta) = \frac{\pi_{\theta}(a \mid s)}{\pi_{\theta_{old}}(a \mid s)}$$

A(advantage)가 양수이면 기대 대비 높은 가치를 음수이면 기대 대비 낮은 가치를 가진다는 것을 알 수 있다.
그렇다면 이걸 어떤 비율로 반영해야하는가? 에 대한 식이다.
분자는 현재 정책이 행동 a를 선택 할 확률
분모는 이전 정책이 행동 a를 선택 할 확률
해석하면 배율이 높을 때(현재 정책이 더 선호 할 때) Advantage가 음수면 다음 정책에서는 이 행동을 더 낮게 선호하도록 목적 함수를 작게 만든다.
(강화학습에서는 loss 부호 반대이고 가중치 업데이트에서 - 부호를 붙인다.)

이 배율을 ratio라고 한다.

최종적으로

$$L(\theta) = r(\theta)A(s, a)$$

위를 바탕으로 이 식이 유도된다.
이제

$$J = -loss$$

를 통해 로지스틱 회귀 때 처럼
J를 정의해서 경사하강법을 가능하게 한다.

$$W := W + \alpha \frac{\partial J}{\partial W}$$

Clip
PPO는 ratio를 $[1 - \epsilon, 1 + \epsilon]$ 구간으로 자른다.
이를 통해 이전 정책에서 크게 벗어나는 것을 막는다.

이를 통해 최종식 유도가 가능하다.
실제 PPO 논문에서는 $Loss^{clip}$ 이외에도 아래 추가 항을 사용한다.

$$Loss = L^{clip} - c_1 L^{VF} + c_2 Entropy$$

c_1, c_2 하이퍼 파라미터로 lr 과 같이 조정 가능하다.
이번 내용을 다루면서 크게 중요하진 않기 때문에 기능들을 정리해보자면

로스	역할
L^{VF}	가치 함수를 학습하기 위한 항
$Entropy$	행동의 무작위성을 주기 위한 항
